Actividad 5 (Evaluación)

Ximena Salazar A01737088

1. Estructura de la base

Hoja del Excel	Registros	Columnas	Uso
Existencias_totales_15_26	2,951	6	Revisión de inventario y correlación.
Histórico_de_Entradas_ySAlidas	55,180	7	Revisión de movimientos y valores extremos.
Histórico_Ventas	21,632	14	Transformaciones y tres modelos de regresión.

Las hojas se trabajaron por separado: representan observaciones diferentes. No se unieron filas sin validar previamente las llaves. En ventas, cada registro corresponde a una **línea de venta**; no equivale a un cliente ni necesariamente a una factura completa.

2. Tratamiento de valores nulos

Se revisaron los tipos de datos con **info()** y los faltantes con **isnull().sum()**. Inventario y movimientos no presentaron nulos. En ventas se identificaron **492 códigos postales faltantes**, equivalentes al 2.27% de sus registros.

Se sustituyeron los CP faltantes por **"SIN DATO"**, conservando las 21,632 líneas. Un código postal es una etiqueta, por lo que no corresponde imputarlo con promedio o mediana. La alternativa de eliminar filas habría reducido ventas a 21,140 registros. Después de la sustitución, las tres hojas quedaron sin valores nulos.

La moneda no está confirmada en el archivo: los importes y errores se expresan en sus unidades monetarias originales.

Outliers y transformaciones

3. Detección de valores extremos

Se utilizaron dos criterios sobre las magnitudes cuantitativas: **desviación estándar** (media ± 3 desviaciones) e **IQR** (Q1 - 1.5 × IQR y Q3 + 1.5 × IQR). Los puntos fuera de los límites se convirtieron temporalmente en nulos en copias de detección, únicamente para contarlos.

Hoja / variable	STD	IQR
Inventario: existencias_id	55	396
Inventario: valor del inventario	25	471
Movimientos: SALIDAS_	994	7,118

Ventas: precio unitario	147	1,076
Ventas: cantidad de unidades	445	3,659
Ventas: importe neto	149	2,150

Los conteos corresponden a **valores por columna**, no a registros únicos; no deben sumarse como si fueran operaciones diferentes. IQR marca más extremos en esta base. La diferencia entre métodos refleja criterios distintos y no demuestra que todos esos puntos sean errores.

Decisión aplicada: se conservaron los extremos en los modelos, ya que pueden representar operaciones reales. Reemplazarlos automáticamente por la mediana modificaría los totales y sus relaciones. Esta decisión también obliga a reconocer la influencia de operaciones grandes sobre la correlación y el R^2.

4. Variables transformadas

Nueva variable	Valor 0	Valor 1	Procedimiento
venta_multiple	Una unidad	Más de una unidad	pd.cut sobre la cantidad original.
marca_vita	Otra marca	Marca VITA	replace sobre la marca original.

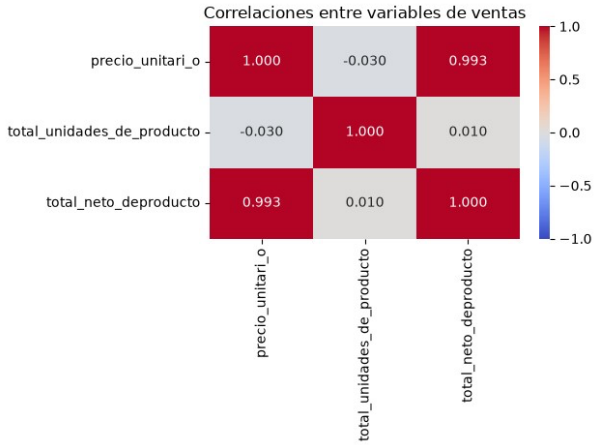
La cantidad mínima observada fue 1 y la máxima 181. Los intervalos (0, 1] y (1, 181] permiten crear una respuesta dicotómica completa. Se conservaron las columnas originales y no se convirtió cada variable de la base en binaria.

Para la regresión logística, los dos predictores se estandarizaron con **StandardScaler**. El escalador se ajustó solo con entrenamiento y luego se aplicó a prueba; así, los datos de prueba no determinaron su media ni su escala.

existencias_id se trató como una cantidad por su contenido. Su definición debe confirmarse con el diccionario del socioformador.

Regresión lineal simple y múltiple

La correlación más alta entre las magnitudes analizadas fue **precio unitario e importe neto: r = 0.992679**. La correlación cantidad-importe fue 0.009578 y existencias-valor del inventario, 0.188426. Una correlación baja por sí sola no descarta una relación condicional o no lineal.



Para los modelos lineales se separaron **12,113 líneas de entrenamiento, 3,029 de validación y 6,490 de prueba**. El corte fue aleatorio y reproducible (random_state=42). La prueba no se usó para elegir el candidato múltiple.

5. Modelo simple

Y = importe neto por línea; P = precio unitario.

$$Y \text{ estimado} = 1{,}071.8804 + 1.000375 \times P$$

Por cada unidad monetaria adicional de precio, el ajuste estima 1.000375 unidades adicionales de importe. El intercepto es el valor de la recta cuando el precio es cero; no debe asumirse como un cargo fijo real.

6. Selección del modelo múltiple

El candidato A incluyó precio y cantidad; el B agregó la marca dicotómica. B obtuvo el mayor R^2 de validación: **0.971060**, frente a **0.970580** de A. Es el mejor de estos dos candidatos según ese criterio, no de todos los modelos posibles.

$$Y \text{ estimado} = 535.0352 + 1.000682 \times P + 385.3465 \times Q - 1{,}282.1591 \times V$$

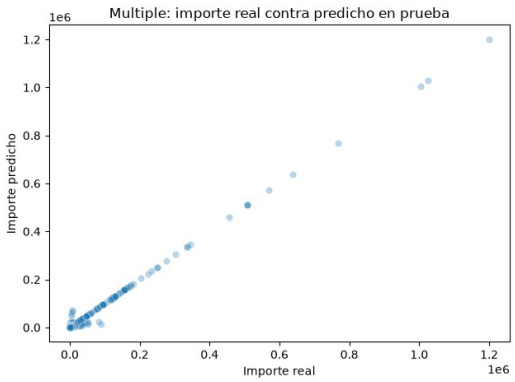
Q = cantidad de unidades; V = 1 para VITA y 0 para otra marca. El coeficiente de precio cambia de 1.000375 a 1.000682 al controlar las demás variables. La cantidad se asocia con 385.3465 unidades monetarias adicionales por unidad, manteniendo precio y marca constantes. El coeficiente de VITA es una asociación condicionada; no demuestra un efecto causal de la marca.

Evaluación de los modelos lineales

Indicador en prueba	Simple	Múltiple B
R^2	0.991712	0.992970
MAE	1,457.07	1,154.39
RMSE	3,152.01	2,902.86
Predicciones negativas	0	1,359 de 6,490

R^2 mide la proporción de variación explicada en el conjunto evaluado. **MAE** es el error absoluto promedio; **RMSE** penaliza más los errores grandes. Los últimos dos indicadores se expresan en las unidades monetarias del archivo.

El múltiple redujo el MAE aproximadamente **20.77%** y el RMSE **7.90%** respecto al simple. Sin embargo, produjo importes negativos en el **20.94%** de las líneas de prueba. Esa limitación es importante aunque su R^2 sea alto: no es apropiado utilizarlo directamente como estimador operativo de importes.



La relación precio-importe es parcialmente contable, porque el importe depende del precio y la cantidad. Por ello, la alta correlación y el R^2 elevado no equivalen a descubrir demanda futura ni a demostrar causalidad. El modelo múltiple es aditivo y no reproduce necesariamente la relación multiplicativa entre precio y cantidad.

Además, la separación se hizo por línea: distintas líneas de una misma factura pueden aparecer en entrenamiento y prueba. Los resultados describen este ejercicio, pero no sustituyen una validación por factura o por tiempo. La elección inicial de la pareja más correlacionada también fue exploratoria sobre la base completa.

Regresión logística y conclusión

La variable fue **venta_multiple**: 13,086 líneas de una unidad y 8,546 de varias (60.49% y 39.51%). Se utilizaron precio unitario y marca_vita. Se excluyó cantidad porque define la respuesta, e importe neto porque incorpora información sobre ella.

Se separó 70% para entrenamiento y 30% para prueba, con estratificación. El ajuste sin pesos siempre predijo una unidad. Se aplicó **class_weight=balanced** para dar mayor peso a la clase menos frecuente, sin remuestrear ni modificar las clases de prueba.

$$z = -0.325527 - 4.368352 \times P^* - 0.241015 \times V^* \quad \text{Probabilidad estimada de varias unidades} = 1 / (1 + \exp(-z))$$

P* y V* son los predictores estandarizados: (valor - media de entrenamiento) / escala de entrenamiento. Medias aproximadas: 4,348.48388 y 0.407278; escalas: 42,827.0034 y 0.491327. Los signos negativos indican menor log-odds de varias unidades, al mantener constante el otro predictor.

Métrica en prueba	**Sin pesos**	**Reponderada**
Precisión de la clase 1	0.00%	45.82%
Exactitud total	60.49%	55.96%
Sensibilidad de la clase 1	0.00%	62.83%
F1 de la clase 1	0.0000	0.5299
Real / predicción	**Una unidad (0)**	**Varias (1)**

Una unidad (0)	2,021	1,905
Varias unidades (1)	953	1,611

La reponderación detectó 1,611 de las 2,564 líneas positivas de prueba, pero generó 1,905 falsos positivos. Su sensibilidad mejoró a cambio de menor exactitud. La precisión de 45.82% significa que menos de la mitad de las predicciones positivas fueron correctas. Las probabilidades reponderadas no deben asumirse calibradas a las frecuencias reales.

Conclusión

El preprocesamiento preservó registros y distinguió faltantes de extremos. El múltiple mejoró el error promedio frente al simple, pero sus importes negativos limitan su uso. La logística reponderada detecta parte de las compras de varias unidades, aunque su precisión es insuficiente para decisiones automáticas